


Grupo 4 – Geração de títulos



Integrantes



David



Gabriel



Giovanni




Luan



Pedro Augusto

Problema a ser resolvido:

Escrever um título de notícia - exige identificar a informação mais central do texto — tarefa que consome tempo do jornalista e que pode ser automatizada.




Bibliotecas de PLN

**Utilizamos nltk e spacy
para**

Stopwords: Retira as stopwords (artigos, preposições,
conjunções e etc)

Stemming: Retira prefixos e sufixos das palavras,
deixando somente



Modelagem de grafos


Vértices - Frases
sem stopwords e
com stemming

Arestas ponderadas -
Índice de similaridade
das frases

Arestas - Frases
semanticamente
relacionadas

Score do vertice -
TextRank


A implementação foi feita em
matriz



TextRank


$$\text{Score}(V_i) = (1 - d) + d \times \sum_j [A_{ji} / \sum_k A_{jk} \times \text{score}(V_j)]$$

- $\text{score}(V_i)$: 'Nível' de importância da frase analisada;
- d : fator de amortecimento;
- $\sum_j$: soma as contribuições de todas as frases relacionadas.
- $\text{score}(V_j)$: importância das frases vizinhas.
- A_{ji} : força da relação entre as frases j e i .
- $\sum_k w_{jk}$: soma de todas as conexões da frase j .



Calculo do indice de similaridade


$$sim(A, B) = \frac{|palavrasemcomum|}{(\log(|A| + 1) + \log(|B| + 1))}$$



Matriz de similaridade

Antes de criar as arestas, calculamos a similaridade entre todos os pares de frases de acordo com a quantidade de palavras em comum;

Fazendo uma matriz simétrica $N \times N$, em que N é o número de frases, para guardar esses valores;



Heurística

O título tem que ser uma frase, mas não pode ser muito grande e nem muito pequena.

Título curto:


- combinar top-1 + top-2;
- Re-extrair candidata
- Mini PageRank sobre top-3 frases

Se ≤ 5 palavras

Título extenso:


- truncar no 1º separadornatural: vírgula ou ";;";
- Sub-frase extraída até a vírgula/ponto e vírgula;

Se > 20 palavras



Como funciona?

- **Texto → Frases → Stopwords + Stemming → Grafo de Similaridade → TextRank → Heurística → Título**
- **Pré-processamento** — segmenta o texto em frases, remove stopwords (PT-BR via spaCy), aplica stemmer implementado manualmente
- **Grafo** — frases = vértices; peso da aresta = número de palavras em comum após pré-processamento
- **TextRank** — variante do PageRank implementada do zero que ranqueia as frases por importância estrutural
- **Heurística** — ajusta o comprimento do título (≤ 5 / 5–20 / > 20 palavras)




Exemplo de entrada e saída 1

Arquivo gerado por LLM;
data/raw/llm_002.txt

O Ministério da Saúde anunciou a ampliação da campanha de vacinação contra a dengue. A vacina estará disponível em postos de saúde de 50 municípios prioritários a partir de julho. O número de casos confirmados da doença já supera 1,5 milhão em 2026. Autoridades de saúde reforçam a importância da eliminação de focos do mosquito Aedes aegypti. A campanha também incluirá ações educativas nas escolas e comunidades de baixa renda.

```
{'title': 'O Ministério da Saúde anunciou a ampliação da campanha de vacinação contra a dengue', 'best_sentence_index': 0, 'graph_stats': {'num_sentences': 5, 'num_edges': 12, 'average_degree': 5.0}}
```




Exemplo de entrada e saída 2

Arquivo presente em:
data/raw/pt/ec_003.txt

O desemprego no Brasil caiu para 6,8% no primeiro trimestre de 2026, menor taxa em 10 anos. O setor de serviços foi o principal gerador de vagas, com 450 mil novos postos formais. A renda média do trabalhador cresceu 3,1% acima da inflação no período. Especialistas alertam que a queda do desemprego pode pressionar salários e inflação. O governo federal atribui o resultado às políticas de incentivo ao emprego formal.

```
{'title': 'Especialistas alertam que a queda do desemprego pode pressionar salários e inflação',
```




Exemplo de entrada e saída 3

Trecho retirado do site
jornal.unesp.br


“(...)dos carros elétricos aos equipamentos militares de ponta, os minerais críticos e as terras raras tomam o lugar do petróleo como recursos naturais mais valiosos. Risco é que passagem para nova economia verde reproduza antigas relações de dependência, limitando países do Sul Global ao papel de exportadores de matéria-prima.”

```
{'title': 'Dos carros elétricos aos equipamentos militares de ponta',
```




Análise de resultados

Após alguns testes, observou-se que, por utilizar um rank de frases já existentes no texto, e não ter uma análise de contexto para as entradas, a condensação de um input para criação de títulos para artigos pode-se mostrar ineficiente, uma vez que a(as) frase(s) podem não expressar a devida ideia central.



Uso de LLM

- **Geração de arquivos de input;**
- **Planejamento das etapas de desenvolvimento;**
- **Auxiliar nos códigos de teste;**



Muito obrigado!

